



UNIVERSIDAD NACIONAL DEL
ALTIPLANO
FACULTAD DE INGENIERÍA ESTADÍSTICA E
INFORMÁTICA
ESCUELA PROFESIONAL DE INGENIERÍA ESTADÍSTICA
E INFORMÁTICA



Transfer Learning con ResNet-18 para Clasificación de Biomas de la Amazonía Peruana

*Transfer Learning with ResNet-18 for Classification of Peruvian Amazon
Biomes*

Cauna Huanca, Jhoel Edu¹ Huaraya Chipana, Junior Beltrán¹ Vilca
Choquemamani, Leidy Nayely¹

¹Universidad Nacional del Altiplano, Puno, Perú

Docente: Aleman Gonzales, Leonid

Curso: Ciencia de Datos – VIII Semestre – 2025-II

Resumen: La Amazonía Peruana constituye uno de los ecosistemas más biodiversos del planeta, cuya clasificación automática es fundamental para tareas de conservación y monitoreo ambiental. En este trabajo se presenta un sistema de clasificación de biomas amazónicos utilizando Transfer Learning con la arquitectura ResNet-18 pre-entrenada en ImageNet. Se emplea el dataset BiomePeruvianAmazon2023, que contiene 14 clases de ecosistemas. El modelo implementa feature extraction con capas convolucionales congeladas, optimización mediante Adam con learning rate scheduling, y data augmentation para mejorar la generalización. Se presenta un análisis exhaustivo incluyendo matriz de confusión, métricas por clase (precision, recall, F1-score) y visualización de predicciones. Los resultados demuestran la efectividad del Transfer Learning para clasificación ambiental con recursos computacionales limitados.

Palabras clave: Transfer Learning, Deep Learning, ResNet, Clasificación de Imágenes, Amazonía Peruana, Biomas, Redes Neuronales Convolucionales

Abstract: The Peruvian Amazon constitutes one of the most biodiverse ecosystems on the planet, whose automatic classification is fundamental for conservation and environmental monitoring tasks. This work presents a classification system for Amazonian biomes using Transfer Learning with the ResNet-18 architecture pre-trained on ImageNet. The BiomePeruvianAmazon2023 dataset is used, containing 14 ecosystem classes. The model implements feature extraction with frozen convolutional layers, Adam optimization with learning rate scheduling, and

data augmentation to improve generalization. A comprehensive analysis is presented including confusion matrix, per-class metrics (precision, recall, F1-score) and prediction visualization. Results demonstrate the effectiveness of Transfer Learning for environmental classification with limited computational resources.

Keywords: Transfer Learning, Deep Learning, ResNet, Image Classification, Peruvian Amazon, Biomes, Convolutional Neural Networks

1. Introducción

La Amazonía Peruana cubre aproximadamente el 60 % del territorio nacional y alberga una de las mayores biodiversidades del mundo [3]. La correcta identificación y clasificación de los diferentes ecosistemas o biomas que componen esta región es crucial para el manejo forestal sostenible, la conservación de especies y el monitoreo de cambios ambientales.

Tradicionalmente, la clasificación de ecosistemas amazónicos ha dependido de expertos botánicos y ecólogos que realizan trabajo de campo extensivo. Sin embargo, este enfoque presenta limitaciones significativas: alto costo, tiempo considerable y dependencia de personal altamente especializado [2].

El aprendizaje profundo (*deep learning*) ha revolucionado el campo de la visión por computadora, permitiendo la clasificación automática de imágenes con precisiones que rivalizan con expertos humanos [5]. No obstante, entrenar redes neuronales profundas desde cero requiere grandes cantidades de datos etiquetados y recursos computacionales considerables.

El *Transfer Learning* (aprendizaje por transferencia) emerge como una solución a estos desafíos, permitiendo aprovechar el conocimiento adquirido por modelos entrenados en datasets masivos como ImageNet para aplicarlo a nuevas tareas relacionadas [6].

Este trabajo tiene como **objetivo principal** desarrollar un sistema de clasificación de biomas de la Amazonía Peruana utilizando Transfer Learning con la arquitectura ResNet-18, demostrando que técnicas avanzadas de deep learning pueden aplicarse exitosamente a problemas de clasificación ambiental con datos peruanos.

2. Marco Teórico

2.1. Redes Neuronales Convolucionales (CNN)

Las Redes Neuronales Convolucionales son arquitecturas especializadas en el procesamiento de datos con estructura de grilla, como imágenes [5]. La operación fundamental es la **convolución 2D**:

$$(I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n) \quad (1)$$

donde I representa la imagen de entrada, K es el kernel o filtro convolucional, y (i, j) son las coordenadas espaciales.

Una CNN típica consta de:

- **Capas convolucionales:** Extraen características mediante filtros aprendidos
- **Capas de pooling:** Reducen dimensionalidad espacial
- **Capas completamente conectadas:** Realizan clasificación final

La operación de **Max Pooling** reduce la dimensión espacial:

$$y_{i,j} = \max_{(m,n) \in \mathcal{R}_{i,j}} x_{m,n} \quad (2)$$

donde $\mathcal{R}_{i,j}$ define la región de pooling.

2.2. Función de Activación ReLU

La función ReLU (*Rectified Linear Unit*) introduce no-linealidad:

$$\text{ReLU}(x) = \max(0, x) \quad (3)$$

Su derivada permite gradientes eficientes durante backpropagation:

$$\frac{\partial \text{ReLU}(x)}{\partial x} = \begin{cases} 1 & \text{si } x > 0 \\ 0 & \text{si } x \leq 0 \end{cases} \quad (4)$$

2.3. Batch Normalization

La normalización por lotes estabiliza el entrenamiento [8]:

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \quad (5)$$

$$y_i = \gamma \hat{x}_i + \beta \quad (6)$$

donde μ_B y σ_B^2 son la media y varianza del mini-batch, y γ, β son parámetros aprendibles.

2.4. Arquitecturas Residuales (ResNet)

Las redes profundas tradicionales sufren el problema de *degradación del gradiente*. ResNet [1] soluciona esto mediante **bloques residuales** con conexiones de salto (*skip connections*):

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x} \quad (7)$$

donde $\mathbf{x}$ es la entrada, $\mathbf{y}$ es la salida, y $\mathcal{F}(\mathbf{x}, \{W_i\})$ representa la transformación residual aprendida. Esta formulación permite que la red aprenda el *residuo* $\mathcal{F}(\mathbf{x})$ en lugar de la transformación completa.

ResNet-18 contiene 18 capas con la siguiente estructura:

- 1 capa convolucional inicial (7×7 , 64 filtros)
- 4 grupos de bloques residuales (2 bloques cada uno)
- 1 capa de global average pooling
- 1 capa completamente conectada (clasificador)

Total de parámetros: ≈ 11.7 millones.

2.5. Transfer Learning

El Transfer Learning se basa en transferir conocimiento de una tarea fuente $\mathcal{T}_S$ a una tarea objetivo $\mathcal{T}_T$ [4]. Formalmente:

$$\mathcal{D}_S = \{(\mathbf{x}_i^S, y_i^S)\}_{i=1}^{n_S}, \quad \mathcal{D}_T = \{(\mathbf{x}_j^T, y_j^T)\}_{j=1}^{n_T} \quad (8)$$

donde típicamente $n_S \gg n_T$.

Existen tres estrategias principales:

1. **Feature extraction**: Capas convolucionales congeladas, solo se entrena el clasificador
2. **Fine-tuning**: Se descongelan algunas capas superiores
3. **Full training**: Se entrena toda la red (baseline)

En este trabajo se implementa **feature extraction**, donde:

$$\theta_{conv} \leftarrow \theta_{conv}^{ImageNet} \quad (\text{congelados}) \quad (9)$$

$$\theta_{fc} \leftarrow \arg \min_{\theta_{fc}} \mathcal{L}(\theta_{fc}; \mathcal{D}_T) \quad (10)$$

2.6. Función de Pérdida: Cross-Entropy

Para clasificación multiclase se utiliza la **entropía cruzada categórica**:

$$\mathcal{L}_{CE} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c}) \quad (11)$$

donde N es el número de muestras, C es el número de clases, $y_{i,c}$ es la etiqueta one-hot, y $\hat{y}_{i,c}$ es la probabilidad predicha.

La función **Softmax** convierte los logits en probabilidades:

$$\sigma(z_i) = \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}}, \quad \sum_{i=1}^C \sigma(z_i) = 1 \quad (12)$$

2.7. Optimizador Adam

Adam (*Adaptive Moment Estimation*) combina momentum y RMSprop [7]:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (13)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (14)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (15)$$

$$\theta_t = \theta_{t-1} - \frac{\alpha}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t \quad (16)$$

donde $g_t = \nabla_{\theta} \mathcal{L}(\theta_{t-1})$, $\beta_1 = 0,9$, $\beta_2 = 0,999$, $\epsilon = 10^{-8}$.

2.8. Learning Rate Scheduling

El scheduler **StepLR** reduce la tasa de aprendizaje:

$$\eta_t = \eta_0 \cdot \gamma^{\lfloor t/s \rfloor} \quad (17)$$

donde η_0 es el learning rate inicial, γ es el factor de decaimiento, y s es el tamaño del paso (step size).

2.9. Data Augmentation

El aumento de datos aplica transformaciones para regularizar el modelo:

$$\tilde{\mathcal{D}} = \{(\mathbf{T}(\mathbf{x}_i), y_i) : (\mathbf{x}_i, y_i) \in \mathcal{D}\} \quad (18)$$

Las transformaciones utilizadas incluyen:

- **Volteo horizontal:** $\mathbf{I}'(x, y) = \mathbf{I}(W - x, y)$
- **Rotación:** $\mathbf{R}_{\theta} = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}$
- **Color Jitter:** Perturbaciones en brillo, contraste y saturación

2.10. Métricas de Evaluación

Para evaluar el rendimiento se utilizan las siguientes métricas:

Precisión (Precision):

$$\text{Precision} = \frac{TP}{TP + FP} \quad (19)$$

Exhaustividad (Recall):

$$\text{Recall} = \frac{TP}{TP + FN} \quad (20)$$

F1-Score (media armónica):

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (21)$$

Accuracy global:

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbb{K}[\hat{y}_i = y_i] \quad (22)$$

3. Metodología

3.1. Dataset: BiomePeruvianAmazon2023

Se utiliza el dataset **BiomePeruvianAmazon2023** disponible en Kaggle, que contiene imágenes de 5 clases de componentes forestales amazónicos: *bark* (corteza), *canopy* (dosel), *leaf* (hoja), *profile* (perfil) y *sap* (savia).

La Figura 1 muestra la distribución de imágenes por clase.




Figura 1: Distribución del número de imágenes por clase en el dataset BiomePeruvianAmazon2023.

La Figura 2 presenta ejemplos visuales del dataset.




Figura 2: Muestras representativas del dataset BiomePeruvianAmazon2023.

3.2. Preprocesamiento

Las imágenes se procesan con los siguientes pasos:

1. **Redimensionamiento:** 224×224 píxeles
2. **Normalización ImageNet:**

$$\mathbf{x}_{norm} = \frac{\mathbf{x} - \boldsymbol{\mu}}{\boldsymbol{\sigma}} \quad (23)$$

donde $\boldsymbol{\mu} = [0,485, 0,456, 0,406]$ y $\boldsymbol{\sigma} = [0,229, 0,224, 0,225]$

3.3. División del Dataset

El dataset se divide estratificadamente:

$$|\mathcal{D}_{train}| = 0,8 \cdot |\mathcal{D}|, \quad |\mathcal{D}_{val}| = 0,2 \cdot |\mathcal{D}| \quad (24)$$

3.4. Configuración del Modelo

Se utiliza ResNet-18 pre-entrenada en ImageNet con la siguiente modificación:

$$fc_{nuevo} = \text{Dropout}(0,3) \rightarrow \text{Linear}(512, 5) \quad (25)$$

Parámetros del modelo:

- Parámetros totales: $\approx 11.2\text{M}$
- Parámetros entrenables: $\approx 7,182$ (0.06 %)

3.5. Algoritmo de Entrenamiento

El Algoritmo 1 describe el proceso de entrenamiento.

Algorithm 1 Entrenamiento Transfer Learning**Require:** Dataset $\mathcal{D}$, modelo ResNet-18, épocas E **Ensure:** Modelo entrenado θ^*

```

1: Cargar pesos ImageNet  $\theta_{conv}$ 
2: Congelar  $\theta_{conv}$ 
3: Inicializar  $\theta_{fc}$  aleatorio
4:  $\eta \leftarrow 0,001$ ,  $best\_acc \leftarrow 0$ 
5: for  $epoch \leftarrow 1$  to  $E$  do
6:   for cada batch  $(\mathbf{X}, \mathbf{y})$  en  $\mathcal{D}_{train}$  do
7:      $\hat{\mathbf{y}} \leftarrow \text{forward}(\mathbf{X}; \theta)$ 
8:      $\mathcal{L} \leftarrow \text{CrossEntropy}(\hat{\mathbf{y}}, \mathbf{y})$ 
9:      $\theta_{fc} \leftarrow \theta_{fc} - \eta \cdot \nabla_{\theta_{fc}} \mathcal{L}$ 
10:   end for
11:    $acc_{val} \leftarrow \text{Evaluate}(\mathcal{D}_{val})$ 
12:   if  $acc_{val} > best\_acc$  then
13:      $best\_acc \leftarrow acc_{val}$ 
14:     Guardar  $\theta^*$ 
15:   end if
16:    $\eta \leftarrow \text{StepLR}(\eta; s = 5, \gamma = 0,1)$ 
17: end for
18: return  $\theta^*$ 

```

3.6. Hiperparámetros

La Tabla 1 resume los hiperparámetros utilizados.

Cuadro 1: Configuración de hiperparámetros

Hiperparámetro	Valor
Arquitectura base	ResNet-18
Learning rate inicial (η_0)	0.001
Optimizador	Adam
β_1, β_2	0.9, 0.999
Batch size	32
Épocas	10
Dropout	0.3
Scheduler	StepLR
Step size (s)	5
Gamma (γ)	0.1

4. Resultados

4.1. Curvas de Aprendizaje

La Figura 3 muestra la evolución de pérdida y precisión durante el entrenamiento. Se observa convergencia estable sin signos de sobreajuste, validando la efectividad del Transfer Learning.




Figura 3: Curvas de aprendizaje: pérdida (izquierda) y precisión (derecha) durante 10 épocas de entrenamiento.

4.2. Matriz de Confusión

La Figura 4 presenta la matriz de confusión en el conjunto de validación.




Figura 4: Matriz de confusión para las 5 clases del dataset. Los valores en la diagonal

4.3. Análisis de Predicciones

La Figura 5 muestra ejemplos de predicciones correctas e incorrectas.




Figura 5: Predicciones correctas (arriba, verde) e incorrectas (abajo, rojo).

4.4. Métricas por Clase

La Tabla 2 presenta las métricas de evaluación detalladas por clase.

Cuadro 2: Métricas de clasificación por clase de bioma

Clase	Precision	Recall	F1-Score	Support
bark	0.8571	1.0000	0.9231	6
canopy	1.0000	1.0000	1.0000	12
leaf	0.9333	1.0000	0.9655	14
profile	1.0000	1.0000	1.0000	8
sap	1.0000	0.3333	0.5000	3
Accuracy		0.9535		43
Macro avg	0.9581	0.8667	0.8777	43
Weighted avg	0.9584	0.9535	0.9432	43

El modelo alcanzó una **precisión global del 95.35%** en el conjunto de validación. Se observa un excelente desempeño en las clases *canopy* y *profile* ($F1=1.0$), mientras que la clase *sap* presenta el menor recall (0.33) debido a su baja representación en el dataset (solo 3 muestras de validación).

5. Discusión

Los resultados obtenidos validan la hipótesis de que el Transfer Learning es una técnica efectiva para la clasificación de biomas amazónicos con recursos limitados. Las características

aprendidas en ImageNet, aunque provienen de un dominio diferente (objetos cotidianos), contienen información fundamental sobre texturas, patrones y colores que es transferible al dominio de ecosistemas naturales [6].

Este trabajo se alinea con investigaciones previas como [2] sobre clasificación de especies forestales en la Amazonía Peruana, demostrando que técnicas de deep learning pueden aplicarse exitosamente a problemas ecológicos en el contexto peruano.

Fortalezas del enfoque:

- Reducción significativa del tiempo de entrenamiento
- Menor requerimiento de datos etiquetados
- Pipeline completamente reproducible
- Fácil adaptación a otras arquitecturas

Limitaciones:

- Dependencia de la calidad del dataset
- Evaluación con una sola arquitectura (ResNet-18)
- Ausencia de validación con expertos en ecosistemas

Trabajo futuro:

- Comparación con EfficientNet, DenseNet, Vision Transformer
- Implementación de Grad-CAM para interpretabilidad
- Validación cruzada con ecólogos especialistas
- Ampliación del dataset con más clases y muestras

6. Conclusiones

Este trabajo demuestra la efectividad del Transfer Learning aplicado a la clasificación de biomas de la Amazonía Peruana utilizando ResNet-18 pre-entrenada en ImageNet. Las principales contribuciones son:

1. Desarrollo de un pipeline completo y reproducible para clasificación de ecosistemas amazónicos
2. Demostración de que características de ImageNet son transferibles al dominio de biomas
3. Análisis exhaustivo con múltiples métricas y visualizaciones
4. Base metodológica para futuros proyectos de clasificación ambiental con datos peruanos

Los resultados validan que técnicas avanzadas de inteligencia artificial pueden democratizarse para aplicaciones de conservación ambiental, contribuyendo al monitoreo y protección de la biodiversidad amazónica del Perú.

Agradecimientos

Agradecemos a la Universidad Nacional del Altiplano y a la Facultad de Ingeniería Estadística e Informática por el apoyo brindado. Reconocemos la contribución de la comunidad open source de PyTorch y a los creadores del dataset BiomePeruvianAmazon2023.

Referencias

- [1] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *CVPR*, 770-778.
- [2] Vizcarra, G., Bermejo, D., Mauricio, A., et al. (2021). The Peruvian Amazon forestry dataset. *Ecological Informatics*, 62, 101268.
- [3] Finer, M., Jenkins, C.N., et al. (2014). Oil and gas projects in the Western Amazon. *PLoS ONE*, 3(8), e2932.
- [4] Pan, S.J., & Yang, Q. (2009). A survey on transfer learning. *IEEE TKDE*, 22(10), 1345-1359.
- [5] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [6] Yosinski, J., et al. (2014). How transferable are features in deep neural networks? *NeurIPS*, 27.
- [7] Kingma, D.P., & Ba, J. (2014). Adam: A method for stochastic optimization. *arXiv:1412.6980*.
- [8] Ioffe, S., & Szegedy, C. (2015). Batch normalization. *ICML*, 448-456.
- [9] Wäldchen, J., & Mäder, P. (2018). Plant species identification using computer vision. *Arch. Comp. Methods Eng.*, 25(2), 507-543.
- [10] Paszke, A., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. *NeurIPS*, 32.